Семинар 8 Стандарт МРІ (часть 1)

Михаил Курносов

E-mail: mkurnosov@gmail.com WWW: www.mkurnosov.net

Цикл семинаров «Основы параллельного программирования» Институт физики полупроводников им. А. В. Ржанова СО РАН Новосибирск, 2015



Вычислительные системы с распределенной памятью



- Вычислительная система с распределенной памятью (distributed memory computer system) совокупность вычислительных узлов, взаимодействие между которыми осуществляется через коммуникационную сеть (InfiniBand, Gigabit Ethernet, Cray Gemeni, Fujitsu Tofu, ...)
- Каждый узел имеет множество процессоров/ядер, взаимодействующих через разделяемую память (shared memory)
- Процессоры могут быть многоядерными, ядра могут поддерживать одновременную многопоточность (SMT, Hyper-Threading)

- http://www.top500.org
- http://www.green500.org
- http://www.graph500.org
- http://top50.supercomputers.ru


Вычислительные системы с распределенной памятью



- Вычислительная система с распределенной памятью (distributed memory computer system) совокупность вычислительных узлов, взаимодействие между которыми осуществляется через коммуникационную сеть (InfiniBand, Gigabit Ethernet, Cray Gemeni, Fujitsu Tofu, ...)
- Каждый узел имеет множество процессоров/ядер, взаимодействующих через разделяемую память (shared memory)
- Процессоры могут быть многоядерными, ядра могут поддерживать одновременную многопоточность (SMT, Hyper-Threading)


- http://www.top500.org
- http://www.green500.org
- http://www.graph500.org
- http://top50.supercomputers.ru

Вычислительные кластеры (computer cluster)



- Вычислительные кластеры строятся на базе <u>свободно доступных для приобретения компонентов</u>
- Вычислительные узлы: 2/4-процессорные узлы, 1 8 GiB оперативной памяти на ядро (поток)
- Коммуникационная сеть (сервисная и для обмена сообщениями)
- Подсистема хранения данных (дисковый массивы, параллельные и сетевые файловые системы)
- Система бесперебойного электропитания
- Система охлаждения
- Программное обеспечение: GNU/Linux (NFS, NIS, DNS, ...), MPI (MPICH2, Open MPI), TORQUE/SLURM

Программное обеспечение вычислительных кластеров



Рейтинги мощнейших ВС

- <u>www.top500.org</u> решение системы линейных алгебраических уравнений методом LU-факторизации (High-Performance Linpack, FLOPS Floating-point Operations Per Seconds)
- www.graph500.org алгоритмы на графах (построение графа, обход в ширину, TEPS – Traversed Edges Per Second)
- www.green500.org главный критерий энергоэффективность (объем потребляемой эленктроэнергии, kW)
- http://top50.supercomputers.ru рейтинг мощнейших вычислительных систем СНГ (тест High-Performance Linpack)
- Как создать свой тест производительности?

www.top500.org (Ноябрь 2014)

	NAME	SPECS	SITE	COUNTRY	CORES	RMAX PFLOP/S	POWER MW
1	Tianhe-2 (Milkyway-2)	NUDT, Intel Ivy Bridge (12C, 2.2 GHz) & Xeon Phi (57C, 1.1 GHz), Custom interconnect	NSCC Guangzhou	China	3,120,000	33.9	17.8
2	Titan	Cray XK7, Opteron 6274 (16C 2.2 GHz) + Nvidia Kepler GPU, Custom interconnect	DOE/SC/ORNL	USA	560,640	17.6	8.2
3	Sequoia	IBM BlueGene/Q, Power BQC (16C 1.60 GHz), Custom interconnect	DOE/NNSA/LLNL	USA	1,572,864	17.2	7.9
4	K computer	Fujitsu SPARC64 VIIIfx (8C, 2.0GHz), Custom interconnect	RIKEN AICS	Japan	705,024	10.5	12.7
5	Mira	IBM BlueGene/Q, Power BQC (16C, 1.60 GHz), Custom interconnect	DOE/SC/ANL	USA	786,432	8.59	3.95

- Среднее количество вычислительных ядер в системе: 46 288
- Среднее количество ядер на сокет (процессор): 9 (4, 6, 8, 10, 12, 14, 16)
- Среднее энергопотребление: **836** kW
- Коммуникационная сеть: Infiniband (44%), Gigabit Ethernet (25%), 10 Gigabit Ethernet (15%),
 Custom (10%), Cray (3%)
- Процессоры: Intel (> 80%), IBM Power, AMD Opteron, SPARC64, ShenWei, NEC
- Ускорители (14% систем): Intel Xeon Phi, NVIDIA GPU, ATI/AMD GPU, PESY-SC
- Операционная система: GNU/Linux (96%), IBM AIX (11 шт.), Microsoft (1 шт.)

Стандарт МРІ

- Message Passing Interface (MPI) это стандарт на программный интерфейс коммуникационных библиотек для создания параллельных программ в модели передачи сообщений (message passing)
- Стандарт определяет интерфейс для языков программирования С и Fortran
- Стандарт де-факто для систем с распределенной памятью ("ассемблер" в области параллельных вычислений на системах с распределенной памятью)
- Обеспечивает переносимость программ на уровне исходного кода между разными ВС (Cray, IBM, NEC, Fujitsu, ...)



http://www.mpi-forum.org

Стандарт МРІ

MPI: A Message-Passing Interface Standard Version 3.0

Message Passing Interface Forum

September 21, 2012

```
Blocking Send and Receive Operations
19
20
     3.2.1 Blocking Send
21
     The syntax of the blocking send operation is given below.
22
23
24
     MPI_SEND(buf, count, datatype, dest, tag, comm)
25
                                            initial address of send buffer (choice)
26
       IN
                buf
27
                                            number of elements in send buffer (non-negative inte-
       IN
                count
28
                                            ger)
29
                                            datatype of each send buffer element (handle)
       IN
                datatype
30
                                            rank of destination (integer)
                dest
31
32
                                            message tag (integer)
                 tag
33
                                            communicator (handle)
                comm
34
35
     int MPI_Send(const void* buf, int count, MPI_Datatype datatype, int dest,
36
                    int tag, MPI_Comm comm)
37
38
     MPI_Send(buf, count, datatype, dest, tag, comm, ierror) BIND(C)
         TYPE(*), DIMENSION(..), INTENT(IN) :: buf
39
         INTEGER, INTENT(IN) :: count, dest, tag
40
         TYPE(MPI_Datatype), INTENT(IN) :: datatype
41
         TYPE(MPI_Comm), INTENT(IN) :: comm
42
```

Реализации MPI


- MPICH (Open source, Argone NL, http://www.mcs.anl.gov/research/projects/mpich2)
- Производные от MPICH2: MVAPICH2 (MPICH2 for InfiniBand), IBM MPI, Cray MPI, Intel MPI, HP MPI, Microsoft MPI
- Open MPI (Open source, BSD License, http://www.open-mpi.org)
- Производные от Open MPI: Oracle MPI
- Высокоуровневые интерфейсы
 - ☐ C++: Boost.MPI
 - ☐ Java: Open MPI Java Interface, MPI Java, MPJ Express, ParJava
 - ☐ C#: MPI.NET, MS-MPI
 - Python: mpi4py, pyMPI

Отличия реализаций МРІ

- Спектр поддерживаемых архитектур процессоров: Intel, IBM, ARM, Fujitsu, NVIDIA, AMD
- Типы поддерживаемых коммуникационных технологий/сетей:
 InfiniBand, 10 Gigabit Ethernet, Cray Gemeni, IBM PERCS/5D torus, Fujitsu Tofu, Myrinet, SCI, ...
- Протоколы дифференцированных обменов двусторонних обменов (Point-to-point): хранение списка процессов, подтверждение передачи (АСК), буферизация сообщений, ...
- Коллективные операции обменов информацией: коммуникационная сложность алгоритмов, учет структуры вычислительной системы (torus, fat tree, ...), неблокирующие коллективные обмены (MPI 3.0, методы хранение collective schedule)
- Алгоритмы вложения графов программ в структуры вычислительных систем (MPI topology mapping)
- **Возможность выполнения MPI-функций в многопоточной среде и поддержка ускорителей** (GPU NVIDIA/AMD, Intel Xeon Phi)

Модель программирования


- Программа состоит из N параллельных процессов, которые порождаются при запуске программы (MPI 1) или могут быть динамически созданы во время выполнения (MPI 2)
- Каждый процесс имеет уникальный идентификатор [0, N 1] и изолированное адресное пространство (SPMD)
- Процессы взаимодействуют путем передачи сообщений (message passing)
- Процессы могут образовывать группы для реализации коллективных операций обмена информацией



- Process/thread/task
- Memory (address space)
- Message passing
- Memory access

Понятие коммуникатора (communicator)

- Коммуникатор (communicator) группа процессов, образующая логическую область для выполнения коллективных операций между процессами
- В рамках коммуникатора процессы имеют номера: 0, 1, ..., N 1
- Все MPI-сообщения должны быть связаны с определенным коммуникатором



Коммуникатор MPI_COMM_WORLD включает все процессы

Программный интерфейс МРІ

- Заголовочный файл mpi.h#include <mpi.h>
- Функции, типы данных и именованные константы имеют префикс «MPI_» MPI_Init, MPI_Init_thread, MPI_Send
- Функции возвращают MPI_SUCCESS или код ошибки
- Результаты возвращаются через аргументы функций

Hello, MPI World!

```
#include <stdio.h>
#include <mpi.h>
int main(int argc, char *argv[])
{
    int commsize, rank, len;
    char procname[MPI_MAX_PROCESSOR_NAME];
    MPI_Init(&argc, &argv);
    MPI_Comm_size(MPI_COMM_WORLD, &commsize);
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);
    MPI_Get_processor_name(procname, &len);
    printf("Hello, MPI World! Process %d of %d on node %s.\n",
           rank, commsize, procname);
    MPI_Finalize();
    return 0;
```

Компиляция МРІ-программ

```
Программа на С
$ mpicc -Wall -o hello ./hello.c
# Программа на С++
$ mpicxx -Wall -o hello ./hello.cpp
# Программа на Fortran
 mpif90 -o hello ./hello.f90
```

Запуск MPI-программы на кластере (система SLURM)

```
Формируем паспорт задачи (job-файл)
                                                       Ресурсный запрос
  cat task.job
                                                nodes=2 — два узла кластера
#!/bin/bash
                                                ntasks-per-node=8 — 8 процессов на узле
                                                          man sbatch
#SBATCH --nodes=2 --ntasks-per-node=8
#SBATCH --job-name=MyTask
mpiexec ./hello
# Ставим задачу в очередь
 sbatch ./task.job
Submitted batch job 4285
```

Запуск MPI-программы на кластере (система SLURM)

```
Проверяем состояние задачи в очереди
   squeue
                                     NAME USER ST
                JOBID PARTITION
                                                                        TIME NODES NODELIST(REASON)
                                     MyTask mkurnoso R
                             debug
                                                                        0:01
                                                                                     2 cn[3-4]
                 4285
  Проверяем результат
  cat ./slurm-4285.out
Hello, MPI World! Process 12 of 16 on node cn4.
Hello, MPI World! Process 13 of 16 on node cn4.
Hello, MPI World! Process 14 of 16 on node cn4.
Hello, MPI World! Process 15 of 16 on node cn4.
Hello, MPI World! Process 8 of 16 on node cn4.
Hello, MPI World! Process 9 of 16 on node cn4.
Hello, MPI World! Process 10 of 16 on node cn4.
Hello, MPI World! Process 11 of 16 on node cn4.
Hello, MPI World! Process 4 of 16 on node cn3.
Hello, MPI World! Process 5 of 16 on node cn3.
Hello, MPI World! Process 6 of 16 on node cn3.
Hello, MPI World! Process 0 of 16 on node cn3.
Hello, MPI World! Process 1 of 16 on node cn3.
Hello, MPI World! Process 2 of 16 on node cn3.
Hello, MPI World! Process 3 of 16 on node cn3.
Hello, MPI World! Process 7 of 16 on node cn3.
```

Подсчет количества простых чисел (serial verion)

```
const int a = 1;
const int b = 10000000;
int is prime number(int n)
   int limit = sqrt(n) + 1;
   for (int i = 2; i <= limit; i++) {</pre>
       if (n \% i == 0)
           return 0;
   return (n > 1) ? 1 : 0;
int count_prime_numbers(int a, int b)
   int nprimes = 0;
   if (a <= 2) {
       nprimes = 1;  /* Count '2' as a prime number */
       a = 2;
   /* Loop over odd numbers: a, a + 2, a + 4, ..., b */
   for (int i = a; i <= b; i += 2) {
       if (is_prime_number(i))
           nprimes++;
   return nprimes;
```

Определят, является ли число n простым O(sqrt(n))

Подсчитывает количество простых числе в интервале [a, b]

```
const int a = 1;
const int b = 10000000;
int is prime number(int n)
   int limit = sqrt(n) + 1;
   for (int i = 2; i <= limit; i++) {</pre>
       if (n \% i == 0)
           return 0;
   return (n > 1) ? 1 : 0;
int count_prime_numbers(int a, int b)
   int nprimes = 0;
   if (a <= 2) {
                   /* Count '2' as a prime number */
       nprimes = 1;
       a = 2;
   /* Loop over odd numbers: a, a + 2, a + 4, ..., b */
   for (int i = a; i <= b; i += 2) {
       if (is_prime_number(i))
           nprimes++;
   return nprimes;
```

Распределим итерации цикла между процессами MPI-программы

```
int main(int argc, char **argv)
   MPI_Init(&argc, &argv);
    // Start serial version in process 0
    double tserial = 0;
    if (get_comm_rank() == 0)
        tserial = run serial();
    // Start parallel version
    double tparallel = run_parallel();
    if (get_comm_rank() == 0) {
        printf("Count prime numbers on [%d, %d]\n", a, b);
        printf("Execution time (serial): %.6f\n", tserial);
        printf("Execution time (parallel): %.6f\n", tparallel);
        printf("Speedup (processes %d): %.2f\n", get_comm_size(), tserial / tparallel);
    MPI Finalize();
    return 0;
```

```
double run_serial()
    double t = MPI Wtime();
    int n = count_prime_numbers(a, b);
    t = MPI_Wtime() - t;
    printf("Result (serial): %d\n", n);
    return t;
double run_parallel()
    double t = MPI Wtime();
    int n = count_prime_numbers_par(a, b);
    t = MPI Wtime() - t;
    printf("Process %d/%d execution time: %.6f\n", get comm rank(), get comm size(), t);
    if (get_comm_rank() == 0)
        printf("Result (parallel): %d\n", n);
    return t;
```

```
void get_chunk(int a, int b, int commsize, int rank, int *lb, int *ub)
    /*
     * This algorithm is based on OpenMP 4.0 spec (Sec. 2.7.1, default schedule for loops)
     * For a team of commsize processes and a sequence of n items, let ceil(n ? commsize) be the integer q
     * that satisfies n = commsize * q - r, with 0 \le r \le commsize.
     * Assign q iterations to the first commsize - r processes, and q - 1 iterations to the remaining r processes.
     */
    int n = b - a + 1;
    int g = n / commsize;
    if (n % commsize)
        q++;
    int r = commsize * q - n;
                                             /* Compute chunk size for the process */
    int chunk = q;
    if (rank >= commsize - r)
        chunk = q - 1;
    *lb = a;
                                             /* Determine start item for the process */
    if (rank > 0) {
                                            /* Count sum of previous chunks */
        if (rank <= commsize - r)</pre>
            *lb += q * rank;
        else
            *lb += q * (commsize - r) + (q - 1) * (rank - (commsize - r));
    *ub = *lb + chunk - 1;
```

```
Count prime numbers on [1, 10000000]
                                                         Проблема 1
Process 0/8 execution time: 0.466901
Process 1/8 execution time: 0.780994
                                               Неравномерная загрузка процессов
Process 2/8 execution time: 1.126007
                                                       (load imbalance)
Process 3/8 execution time: 1.125990
Process 4/8 execution time: 1.556572
Process 5/8 execution time: 1.358095
Process 6/8 execution time: 1.556561
Process 7/8 execution time: 1.556546
Execution time (serial): 8.970650
Execution time (parallel): 0.466901
Result (parallel): 664579
Result (serial): 664579
Speedup (processes 8): 19.21 ~
                                            Проблема 2
```

Ускорение в 19 раз?

```
int count prime numbers par(int a, int b)
    int nprimes = 0;
    int lb, ub;
    get_chunk(a, b, get_comm_size(), get_comm_rank(), &lb, &ub);
    /* Count '2' as a prime number */
                                                                       Проблема 1
    if (lb <= 2) {
        nprimes = 1;
                                                          Неравномерная загрузка процессов
        1b = 2;
                                                   Process 0: 0, 1, 2, 3
                                                   Process 1: 4, 5, 6, 7 T_{is\_prime\_number} = O(sqrt(i))
                                                   Process 3: 8, 9, 10, 11
    /* Shift 'a' to odd number */
    if (lb % 2 == 0)
                                                    . . .
        lb++:
    /* Loop over odd numbers: a, a + 2, a + 4, ... , b */
    for (int i = lb; i \le ub; i += 2) {
        if (is_prime_number(i))
            nprimes++;
    int nprimes_global;
    MPI_Reduce(&nprimes, &nprimes_global, 1, MPI_INT, MPI_SUM, 0, MPI_COMM_WORLD);
    return nprimes_global;
```

```
int main(int argc, char **argv)
                                                                  Проблема 2
                                                          Неправильное вычисление
   MPI_Init(&argc, &argv);
                                                            коэффициента ускорения
    // Start serial version in process 0
                                                          Speedup = tserial / tparallel
    double tserial = 0;
    if (get_comm_rank() == 0)
                                                         tparallel — время процесса 0
        tserial = run serial();
                                                           За tparallel надо брать
    // Start parallel version
                                                    наибольшее время выполнения процессов
    double tparallel = run parallel();
    if (get_comm_rank() == 0) {
        printf("Count prime numbers on [%d, %d]\n", a, b);
        printf("Execution time (serial): %.6f\n", tserial);
        printf("Execution time (parallel): %.6f\n", tparallel);
        printf("Speedup (processes %d): %.2f\n", get_comm_size(), tserial / tparallel);
    MPI_Finalize();
    return 0;
```

```
Решение проблемы 2
double run_parallel()
                                                                S = \frac{T_{serial}}{\max(T_0, T_1, ..., T_{N-1})}
    double t = MPI_Wtime();
    int n = count_prime_numbers_par(a, b);
    t = MPI_Wtime() - t;
    printf("Process %d/%d execution time: %.6f\n",
            get_comm_rank(), get_comm_size(), t);
    if (get_comm_rank() == 0)
        printf("Result (parallel): %d\n", n);
    // Собираем в процессе 0 максимальное из времен выполнения
    double tmax;
    MPI_Reduce(&t, &tmax, 1, MPI_DOUBLE, MPI_MAX, 0, MPI_COMM_WORLD);
    return tmax;
```

```
int count_prime_numbers_par(int a, int b)
                                                                   Решение проблемы 1
    int nprimes = 0;
                                                            Циклическое распределение итераций
                                                                        (round-robin)
    /* Count '2' as a prime number */
    int commsize = get_comm_size();
    int rank = get comm rank();
    if (a <= 2) {
        a = 2:
        if (rank == 0)
            nprimes = 1;
    for (int i = a + rank; i <= b; i += commsize) {</pre>
        if (i % 2 > 0 && is_prime_number(i))
            nprimes++;
    int nprimes global = 0;
    MPI_Reduce(&nprimes, &nprimes_global, 1, MPI_INT, MPI_SUM, 0, MPI_COMM_WORLD);
    return nprimes global;
```

Задание

- Разработать на MPI параллельную версию программы подсчета количества простых числе в заданном интервале — написать код функции count_prime_numbers_par()
- Провести анализ масштабируемости параллельной программы
- Шаблон программы находится в каталоге _task