Семинар 9 Стандарт МРІ (часть 2)

Михаил Курносов


E-mail: mkurnosov@gmail.com WWW: www.mkurnosov.net

Цикл семинаров «Основы параллельного программирования» Институт физики полупроводников им. А. В. Ржанова СО РАН Новосибирск, 2015



Модель программирования

- Программа состоит из N параллельных процессов, которые порождаются при запуске программы (MPI 1) или могут быть динамически созданы во время выполнения (MPI 2)
- Каждый процесс имеет уникальный идентификатор [0, N 1] и изолированное адресное пространство (SPMD)
- Процессы взаимодействуют путем передачи сообщений (message passing)
- Процессы могут образовывать группы для реализации коллективных операций обмена информацией



- Process/thread/task
- Memory (address space)
- Message passing
- Memory access

Виды обменов сообщениями в МРІ

Двусторонние обмены (point-to-point communication)


- Один процесс инициирует передачу сообщения (send), другой его принимает (receive)
- Изменение памяти принимающего процесса происходит при его явном участии
- Обмен совмещен с синхронизацией процессов


• Односторонние обмены (one-sided communication, remote memory access)


- Только один процесс явно инициирует передачу/прием сообщения из памяти удаленного процесса
- Синхронизация процессов отсутствует

Виды обменов сообщениями в МРІ

- Двусторонние обмены (point-to-point communication) участвуют два процесса коммуникатора (send, recv)
- Односторонние обмены (one-sided communication) участвуют два процесса коммуникатора (без синхронизации процессов, put, get)
- Коллективные обмены (collective communication) участвуют все процессы коммуникатора (one-to-all broadcast, all-to-one gather, all-to-all broadcast)







Структура сообщения (point-to-point)

• Данные

- Адрес буфера в памяти
- Число элементов в буфере (count)
- Тип данных элементов в буфере (datatype)

Заголовок (envelope)

- Идентификаторы отправителя и получателя (source, destination)
- Коммуникатор (communicator)

Двусторонние обмены (point-to-point)

Блокирующие (Blocking)

- MPI Bsend
- MPI Recv
- MPI Rsend
- MPI Send
- MPI Sendrecv
- MPI Sendrecv replace
- MPI Ssend
- ...

Проверки состояния запросов (Completion/Testing)

- MPI Iprobe
- MPI Probe
- MPI Test{, all, any, some}
- MPI Wait{, all, any, some}
- ...

Неблокирующие (Non-blocking)

- MPI Ibsend
- MPI Irecv
- MPI Irsend
- MPI Isend
- MPI Issend
- ...

Постоянные (Persistent)

- MPI Bsend init
- MPI Recv init
- MPI Send init
- ...
- MPI Start
- MPI Startall

Блокирующие функции Send/Recv

- buf адрес буфера
- count число элементов в буфере
- datatype тип данных элементов в буфере
- dest номер процесса-получателя
- source номер процесса-отправителя или MPI_ANY_SOURCE
- tag тег сообщения или MPI_ANY_TAG
- comm идентификатор коммуникатора или MPI_COMM_WORLD
- status параметры принятого сообщения (содержит поля source, tag)

Соответствие типов данных МРІ типам языка С

MPI datatype	C datatype
MPI_CHAR	char
	(treated as printable character)
MPI_SHORT	signed short int
MPI_INT	signed int
MPI_LONG	signed long int
MPI_LONG_LONG_INT	signed long long int
MPI_LONG_LONG (as a synonym)	signed long long int
MPI_SIGNED_CHAR	signed char
	(treated as integral value)
MPI_UNSIGNED_CHAR	unsigned char
	(treated as integral value)
MPI_UNSIGNED_SHORT	unsigned short int
MPI_UNSIGNED	unsigned int
MPI_UNSIGNED_LONG	unsigned long int
MPI_UNSIGNED_LONG_LONG	unsigned long long int
MPI_FLOAT	float
MPI_DOUBLE	double
MPI_LONG_DOUBLE	long double
MPI_WCHAR	wchar_t
	(defined in <stddef.h>)</stddef.h>
	(treated as printable character)

_Bool
int8_t
int16_t
int32_t
int64_t
uint8_t
uint16_t
uint32_t
uint64_t
float _Complex
float _Complex
double _Complex
long double _Complex

Определение размера принятого сообщения

```
#define NELEMS(x) (sizeof(x) / sizeof((x)[0]))
int main(int argc, char **argv)
                                                                                       Каждый процесс
                                                                                         1, 2, ..., p — 1
    int rank, commsize, len, count, tag = 1;
                                                                                     отправляет корневому
    char host[MPI MAX PROCESSOR NAME], msg[128 + MPI MAX PROCESSOR NAME];
                                                                                     процессу сообщение
   MPI Init(&argc, &argv);
                                                                                      переменной длины
   MPI_Comm_rank(MPI_COMM_WORLD, &rank);
   MPI_Comm_size(MPI_COMM_WORLD, &commsize);
   MPI Get processor name(host, &len);
    if (rank > 0) {
        count = snprintf(msg, NELEMS(msg), "Hello, I am %d of %d on %s", rank, commsize, host) + 1;
        MPI_Send(msg, count, MPI_CHAR, 0, tag, MPI_COMM_WORLD);
    } else {
        MPI Status status;
        for (int i = 1; i < commsize; i++) {
            MPI_Recv(msg, NELEMS(msg), MPI_CHAR, MPI_ANY_SOURCE, tag, MPI_COMM_WORLD, &status);
            MPI Get count(&status, MPI CHAR, &count);
            printf("Message from %d (tag %d, count %d): '%s'\n", status.MPI_SOURCE, status.MPI_TAG, count, msg);
    MPI Finalize();
    return 0;
```

Определение размера принятого сообщения

```
Message from 1 (tag 1, count 27): 'Hello, I am 1 of 16 on cn3'
Message from 2 (tag 1, count 27): 'Hello, I am 2 of 16 on cn3'
Message from 3 (tag 1, count 27): 'Hello, I am 3 of 16 on cn3'
Message from 4 (tag 1, count 27): 'Hello, I am 4 of 16 on cn3'
Message from 5 (tag 1, count 27): 'Hello, I am 5 of 16 on cn3'
Message from 6 (tag 1, count 27): 'Hello, I am 6 of 16 on cn3'
Message from 12 (tag 1, count 28): 'Hello, I am 12 of 16 on cn4'
Message from 7 (tag 1, count 27): 'Hello, I am 7 of 16 on cn3'
Message from 14 (tag 1, count 28): 'Hello, I am 14 of 16 on cn4'
Message from 13 (tag 1, count 28): 'Hello, I am 13 of 16 on cn4'
Message from 15 (tag 1, count 28): 'Hello, I am 15 of 16 on cn4'
Message from 10 (tag 1, count 28): 'Hello, I am 10 of 16 on cn4'
Message from 11 (tag 1, count 28): 'Hello, I am 11 of 16 on cn4'
Message from 8 (tag 1, count 27): 'Hello, I am 8 of 16 on cn4'
Message from 9 (tag 1, count 27): 'Hello, I am 9 of 16 on cn4'
```

Семантика двусторонних обменов (point-to-point)

- Гарантируется сохранение порядка сообщений от каждого процесса-отправителя
- Не гарантируется "справедливость" доставки сообщений от нескольких отправителей

```
CALL MPI_COMM_RANK(comm, rank, ierr)
IF (rank.EQ.0) THEN
        CALL MPI_BSEND(buf1, count, MPI_REAL, 1, tag, comm, ierr)
        CALL MPI_BSEND(buf2, count, MPI_REAL, 1, tag, comm, ierr)
ELSE IF (rank.EQ.1) THEN
        CALL MPI_RECV(buf1, count, MPI_REAL, 0, MPI_ANY_TAG, comm, status, ierr)
        CALL MPI_RECV(buf2, count, MPI_REAL, 0, tag, comm, status, ierr)
END IF
```

Сообщение, отправленное первым send, должно быть получено первым recv

Пример Send/Recv (попытка получить меньше, чем нам отправили)

```
int main(int argc, char **argv)
   int rank, commsize;
   float buf[100];
   MPI Init(&argc, &argv);
   MPI Comm rank(MPI COMM WORLD, &rank);
   MPI Comm size(MPI COMM WORLD, &commsize);
   if (rank == 0) {
        for (int i = 0; i < NELEMS(buf); i++)
            buf[i] = (float)i;
        MPI_Send(buf, NELEMS(buf), MPI_FLOAT, 1, 0, MPI_COMM_WORLD);
   } else if (rank == 1) {
        MPI Status status;
        MPI_Recv(buf, 10, MPI_FLOAT, 0, 0, MPI_COMM_WORLD, &status);
        printf("Master received: ");
        int count;
        MPI Get count(&status, MPI FLOAT, &count);
        for (int i = 0; i < count; i++)
            printf("%f ", buf[i]);
        printf("\n");
                                           Fatal error in MPI Recv:
                                           Message truncated, error stack:
   MPI Finalize();
                                           MPIDI CH3U Receive data found(284): Message from rank 0 and tag 0
   return 0;
                                           truncated; 400 bytes received but buffer size is 40
```

Пример Send/Recv (попытка получить больше, чем нам отправили)

```
int main(int argc, char **argv)
   int rank, commsize;
   float buf[100];
   MPI Init(&argc, &argv);
   MPI Comm rank(MPI COMM WORLD, &rank);
   MPI Comm size(MPI COMM WORLD, &commsize);
   if (rank == 0) {
        for (int i = 0; i < NELEMS(buf); i++)
            buf[i] = (float)i;
       MPI Send(buf, NELEMS(buf), MPI FLOAT, 1, 0, MPI COMM WORLD);
   } else if (rank == 1) {
       MPI Status status;
       MPI Recv(buf, 1000, MPI FLOAT, 0, 0, MPI COMM WORLD, &status);
        printf("Master received: ");
        int count;
       MPI Get count(&status, MPI FLOAT, &count);
        for (int i = 0; i < count; i++)
            printf("%f ", buf[i]);
        printf("\n");
   MPI Finalize();
```

return 0;

Master received: 0.00 1.00 2.00 3.00 4.00 5.00 6.00 7.00 8.00 9.00 ...

Информация о принятом сообщении

■ Записывает в count число принятых элементов типа datatype (информация о них хранится в переменной status)

- Блокирует выполнение процесса, пока не поступит сообщение (source, tag, comm)
- Информация о сообщении возвращается через параметр status
- Далее, пользователь может создать буфер нужного размера и извлечь сообщение функцией MPI_Recv

Информация о принятом сообщении

```
int main(int argc, char **argv)
    int rank, commsize, count;
   MPI_Init(&argc, &argv);
   MPI Comm rank(MPI COMM WORLD, &rank);
    MPI_Comm_size(MPI_COMM_WORLD, &commsize);
    if (rank == 0) {
        float buf[10];
        for (int i = 0; i < 10; i++)
            buf[i] = i * 10.0;
        MPI_Send(buf, 10, MPI_FLOAT, 2, 0, MPI_COMM_WORLD);
    } else if (rank == 1) {
        int buf[6];
        for (int i = 0; i < 6; i++)
            buf[i] = i * 2 + 1;
        MPI_Send(buf, 6, MPI_INT, 2, 1, MPI_COMM_WORLD);
```

Процесс 0


отправляет 10 элементов типа float

Процесс 1 отправляет 6 элементов типа int


Информация о принятом сообщении (2)

```
else if (rank == 2) {
    MPI Status status;
    for (int m = 0; m < 2; m++) {
        MPI_Probe(MPI ANY SOURCE, MPI ANY TAG, MPI COMM WORLD, &status);
        if (status.MPI TAG == 0) {
            MPI Get count(&status, MPI FLOAT, &count);
            float *buf = malloc(sizeof(*buf) * count);
            MPI Recv(buf, count, MPI FLOAT, status.MPI SOURCE, status.MPI TAG, MPI COMM WORLD, &status);
            printf("Master received: ");
            for (int i = 0; i < count; i++)
                printf("%.2f\n", buf[i]);
            free(buf);
        } else if (status.MPI TAG == 1) {
            MPI Get count(&status, MPI_INT, &count);
            int *buf = malloc(sizeof(*buf) * count);
            MPI Recv(buf, count, MPI INT, status.MPI SOURCE, status.MPI TAG, MPI COMM WORLD, &status);
            printf("Master received: ");
            for (int i = 0; i < count; i++)
                                                                                      Процесс 2
                printf("%d\n", buf[i]);
            free(buf);
                                                                                  определяет тип
                                                                                   принимаемых
                                                                                    сообщений
MPI_Finalize(); return 0;
                                                                                       по тегу
```

Взаимная блокировка процессов (deadlock)



Взаимная блокировка процессов (deadlock)



- Поменять порядок операций Send/Recv
- Использовать неблокирующие операции Isend/Irecv/Wait
- Использовать функцию MPI_Sendrecv

Совмещение передачи и приема

- Предотвращает возникновение взаимной блокировки при вызове Send/Recv
- Не гарантирует защиту от любых взаимных блокировок!

Передача сообщения по кольцу

```
enum {
    BUFSIZE = 100
};
char rbuf[BUFSIZE], sbuf[BUFSIZE];
int main(int argc, char **argv)
    int rank, commsize;
   MPI_Init(&argc, &argv);
    MPI Comm rank(MPI COMM WORLD, &rank);
    MPI Comm size(MPI COMM WORLD, &commsize);
    int prev = (rank - 1 + commsize) % commsize;
    int next = (rank + 1) % commsize;
    MPI_Send(&sbuf, BUFSIZE, MPI_CHAR, next, 0, MPI_COMM_WORLD);
    MPI_Recv(&rbuf, BUFSIZE, MPI_CHAR, prev, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
    printf("Process %d received from %d\n", rank, prev);
    MPI Finalize();
    return 0;
```

Process 1 received from 0 Process 2 received from 1 Process 3 received from 2 Process 0 received from 3

Передача сообщения по кольцу (2)

```
enum {
    BUFSIZE = 1000000
};
char rbuf[BUFSIZE], sbuf[BUFSIZE];
int main(int argc, char **argv)
    int rank, commsize;
    MPI_Init(&argc, &argv);
    MPI Comm rank(MPI COMM WORLD, &rank);
    MPI Comm size(MPI COMM WORLD, &commsize);
    int prev = (rank - 1 + commsize) % commsize;
    int next = (rank + 1) % commsize;
    MPI Send(&sbuf, BUFSIZE, MPI_CHAR, next, 0, MPI_COMM_WORLD);
    MPI_Recv(&rbuf, BUFSIZE, MPI_CHAR, prev, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
    printf("Process %d received from %d\n", rank, prev);
    MPI Finalize();
    return 0;
```

Программа зависла (deadlock)

- Процесс 0 ждет когда процесс 1 примет сообщение
- Процесс 1 ждет 2
- Процесс 2 ждет 3
- Процесс три ждет 1

Цикл в графе зависимости

Для небольших сообщений MPI Send не блокирует выполнение — сообщение сохраняется во внутреннем буфере

Передача сообщения по кольцу (3)

```
enum {
    BUFSIZE = 1000000
};
char rbuf[BUFSIZE], sbuf[BUFSIZE];
int main(int argc, char **argv)
    int rank, commsize;
    MPI_Init(&argc, &argv);
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);
    MPI_Comm_size(MPI_COMM_WORLD, &commsize);
    int prev = (rank - 1 + commsize) % commsize;
    int next = (rank + 1) % commsize;
    MPI_Sendrecv(&sbuf, BUFSIZE, MPI_CHAR, next, 0, &rbuf, BUFSIZE, MPI_CHAR, prev, 0,
                 MPI_COMM_WORLD, MPI_STATUS_IGNORE);
    printf("Process %d received from %d\n", rank, prev);
    MPI Finalize();
    return 0;
```

Задание

Программа Ring

Написать программу передачи сообщения по кольцу:
 процесс 0 передает сообщение процессу N — 1 и принимает сообщение от процесса 1, процесс 1 передает сообщение процессу 0 и принимает от 2 и т.д.

Программа PingPong

- Написать программу, в которой процесс 0 передает сообщение процессу 1,
 процесс 1 принимает сообщение и возвращает его обратно процессу 0
- В процессе 0 измерить суммарное время выполнения Send + Recv:
 - 1) когда оба процесс запущена на одном узле (обмены через общую память)
 - 2) когда процессы на разных узлах (обмены через Infiniband QDR)