Семинар 11 Стандарт МРІ (часть 4)

Михаил Курносов

E-mail: mkurnosov@gmail.com WWW: www.mkurnosov.net

Цикл семинаров «Основы параллельного программирования» Институт физики полупроводников им. А. В. Ржанова СО РАН Новосибирск, 2015



- Как передать структуру C/C++ в другой процесс?
- Как передать другом процессу столбец матрицы?
 (в C/C++ массивы хранятся в памяти строка за строкой row-major order, в Fortran столбец за столбцом column-major order)
- Как реализовать прием сообщений различных размеров (заголовок сообщения содержит его тип, размер)?

```
typedef struct {
                                 Как передать массив частиц другому процессу?
    double x;
    double y;
    double z;
    double f;
    int data[8];
} particle_t;
int main(int argc, char **argv)
    int rank;
    MPI_Init(&argc, &argv);
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);
    int nparticles = 1000;
    particle_t *particles = malloc(sizeof(*particles) * nparticles);
```

```
/* Create data type for message of type particle_t */
MPI Datatype types[5] = {MPI DOUBLE, MPI DOUBLE, MPI DOUBLE, MPI DOUBLE,
                         MPI INT};
int blocklens[5] = {1, 1, 1, 1, 8};
MPI Aint displs[0];
displs[0] = offsetof(particle t, x);
displs[1] = offsetof(particle t, y);
displs[2] = offsetof(particle t, z);
displs[3] = offsetof(particle t, f);
displs[4] = offsetof(particle t, data);
MPI_Datatype parttype;
MPI_Type_create_struct(5, blocklens, displs,
                       types, &parttype);
MPI_Type_commit(&parttype);
```

```
// size = 64
struct {
   double x;
              // offset 0
   double y; // offset 8
   double z; // offset 16
   double f; // offset 24
   int data[8]; // offset 32
```

```
Компилятор выравнивает структуру
                // size = 72
struct {
   double x;
              // offset 0
   double y;
              // offset 8
   double z; // offset 16
             // offset 24
   int type
   double f; // offset 32
   int data[8]; // offset 40
```

```
/* Init particles */
if (rank == 0) {
    // Random positions in simulation box
    for (int i = 0; i < nparticles; i++) {</pre>
        particles[i].x = rand() % 10000;
        particles[i].y = rand() % 10000;
        particles[i].z = rand() % 10000;
        particles[i].f = 0.0;
MPI_Bcast(particles, nparticles, parttype, 0, MPI_COMM_WORLD);
// code ...
MPI_Type_free(&parttype);
free(particles);
MPI_Finalize( );
return 0;
```

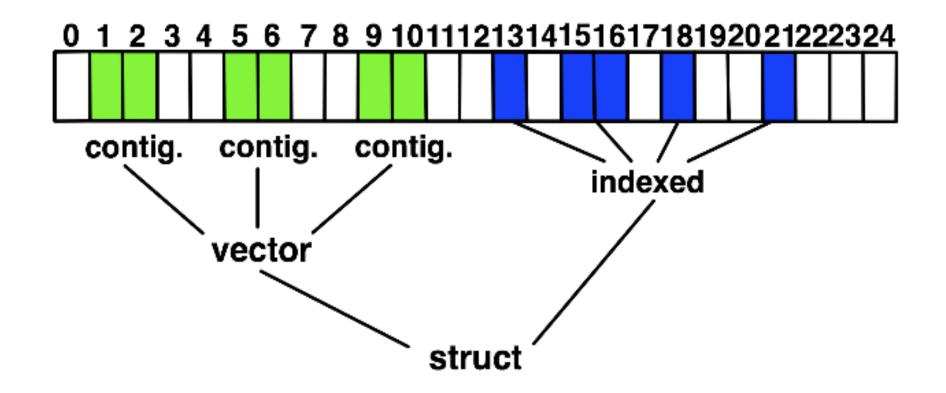
MPI_Type_contiguous

- Непрерывная последовательность в памяти (массив) элементов типа oldtype
- Одномерный массив



• Пример

- oldtype = {(double, 0), (char, 8)}
 (1 double и 1 char, 0 и 8 это смещения)
- MPI_Type_contiguous(3, MPI_Datatype oldtype, &newtype)
- newtype = {(double, 0), (char, 8), (double, 16), (char, 24), (double, 32), (char, 40)}



```
int MPI_Type_vector(int count, int blocklength, int stride,
                     MPI Datatype oldtype, MPI Datatype *newtype)
int MPI_Type_indexed(int count, const int array_of_blocklengths[],
                      const int array of displacements[],
                      MPI Datatype oldtype, MPI Datatype *newtype)
int MPI Type create struct(int count,
                            const int array of blocklengths[],
                            const MPI Aint array_of_displacements[],
                             const MPI Datatype array of types[],
                            MPI Datatype *newtype)
int MPI Type create subarray(int ndims, const int array of sizes[],
                               const int array of subsizes[],
                               const int array of starts[],
                               int order, MPI Datatype oldtype,
                               MPI Datatype *newtype)
```

Выбор типа данных

- 1. Предопределенные типы (MPI_DOUBLE, MPI_INT, MPI_CHAR, ...)
- 2. contig
- 3. vector
- 4. index_block
- 5. index
- 6. struct

Slower

Упаковка данных (MPI Pack)

```
int main(int argc, char **argv)
    int rank, packsize, position;
    int a;
    double b;
    uint8_t packbuf[100];
    MPI Init(&argc, &argv);
    MPI Comm rank(MPI COMM WORLD, &rank);
    if (rank == 0) {
        a = 15;
        b = 3.14;
```

Как передать int a и double b одним сообщением?

Упаковка данных (MPI Pack)

```
packsize = 0; /* Pack data into the buffer */
    MPI_Pack(&a, 1, MPI_INT, packbuf, 100, &packsize, MPI_COMM_WORLD);
    MPI_Pack(&b, 1, MPI_DOUBLE, packbuf, 100, &packsize, MPI_COMM_WORLD);
MPI_Bcast(&packsize, 1, MPI_INT, 0, MPI_COMM_WORLD);
MPI Bcast(packbuf, packsize, MPI_PACKED, 0, MPI COMM WORLD);
if (rank != 0) {
    position = 0; /* Unpack data */
    MPI Unpack(packbuf, packsize, &position, &a, 1, MPI INT, MPI COMM WORLD);
    MPI_Unpack(packbuf, packsize, &position, &b, 1, MPI_DOUBLE,
               MPI COMM WORLD);
printf("Process %d unpacked %d and %lf\n", rank, a, b);
MPI Finalize( );
return 0;
```



width

1)Вычисляется среднее квадратичное значений всех пикселей (RMS)

RMS = sqrt(sum(L[i][j] * L[i][j]) / (H * W))

2) Каждый пиксель L[i,j] преобразуется

$$L[i,j] = 2 * L[i, j] — RMS$$

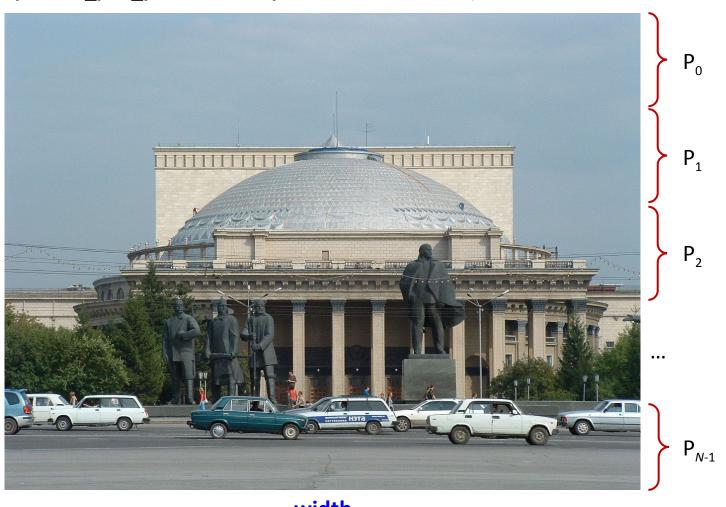
if $(L[i,j] < 0)$ then $L[i,j] = 0$
if $(L[i,j] > 255)$ then $L[i,j] = 255$





```
npixels = width * height;
npixels_per_process = npixels / commsize;
```

height



1D decomposition



width

```
int main(int argc, char *argv[]) {
   MPI Init(&argc, &argv);
    int rank, commsize;
   MPI Comm rank(MPI COMM WORLD, &rank);
   MPI Comm size(MPI COMM WORLD, &commsize);
    int width, height, npixels, npixels_per_process;
   uint8 t *pixels = NULL;
    if (rank == 0) {
       width = 15360; // 15360 x 8640: 16K Digital Cinema (UHDTV) ~ 127 MiB
       height = 8640;
       npixels = width * height;
       pixels = xmalloc(sizeof(*pixels) * npixels);
       for (int i = 0; i < npixels; i++)</pre>
            pixels[i] = rand() % 255;
   MPI_Bcast(&npixels, 1, MPI_INT, 0, MPI_COMM_WORLD); // Send size of image
    npixels per process = npixels / commsize;
    uint8_t *rbuf = xmalloc(sizeof(*rbuf) * npixels_per_process);
   // Send a part of image to each process
   MPI_Scatter(pixels, npixels_per_process, MPI_UINT8_T, rbuf, npixels_per_process, MPI_UINT8_T,
                0, MPI COMM WORLD);
```

```
int sum local = 0;
for (int i = 0; i < npixels_per_process; i++)</pre>
    sum local += rbuf[i] * rbuf[i];
/* Calculate global sum of the squares */
int sum = 0;
// MPI_Reduce(&sum_local, &sum, 1, MPI_INT, MPI_SUM, 0, MPI_COMM_WORLD);
MPI Allreduce(&sum local, &sum, 1, MPI INT, MPI SUM, MPI COMM WORLD);
double rms;
// if (rank == 0)
rms = sqrt((double)sum / (double)npixels);
//MPI Bcast(&rms, 1, MPI DOUBLE, 0, MPI COMM WORLD);
```

```
/* Contrast operation on subimage */
for (int i = 0; i < npixels_per_process; i++) {</pre>
    int pixel = 2 * rbuf[i] - rms;
    if (pixel < 0)</pre>
        rbuf[i] = 0;
    else if (pixel > 255)
        rbuf[i] = 255;
    else
        rbuf[i] = pixel;
MPI Gather(rbuf, npixels per process, MPI UINT8 T, pixels,
           npixels per process, MPI_UINT8_T, 0, MPI_COMM_WORLD);
if (rank == 0)
    // Save image...
free(rbuf);
if (rank == 0)
    free(pixels);
MPI_Finalize();
```

• Равномерно ли пиксели изображения распределяются по процессам? npixels_per_process = npixels / commsize;

• Загрузка исходного изображения

- Корневой процесс загружает изображение и рассылает части остальным (изображение может не поместиться в память одного узла)
- ✓ Каждый процесс загружает часть изображения (MPI I/O, NFS, Lustre)

• Обработка изображения

✓ Вычисление RMS: MPI_Reduce + MPI_Bcast или MPI_Allreduce

Сохранение изображения

- ✓ Сборка Gather изображение формируется в памяти процесс 0
- ✓ Сборка Send/Recv части изображения последовательно сохраняются в файл

Домашнее чтение

- Pavan Balaji, William Gropp, Torsten Hoefler, Rajeev Thakur. Advanced MPI Programming // Tutorial at SC14, November 2014, http://www.mcs.anl.gov/~thakur/sc14-mpi-tutorial/
- Torsten Hoefler. Advanced MPI 2.2 and 3.0 Tutorial // http://htor.inf.ethz.ch/teaching/mpi_tutorials/cscs12/hoefler_tutorial_advanced-mpi-2.2-and-mpi-3.0_cscs.pdf

