# Семинар 14 Технология CUDA Потоки CUDA

#### Михаил Курносов

E-mail: mkurnosov@gmail.com WWW: www.mkurnosov.net


Цикл семинаров «Основы параллельного программирования» Институт физики полупроводников им. А. В. Ржанова СО РАН Новосибирск, 2015




#### **Streaming Multiprocessor (SM)**

192 cores, 32 special function units, 32 LD/ST units, 4 warp schedulers

- Блоки потоков распределяются по SM
- Если число блоков меньше количества SM,
   то часть процессоров GPU простаивает
- Порядок выполнения блоков заранее неизвестен алгоритмы для GPU не должны быть чувствительны к порядку выполнения блоков



**NVIDIA GeForce 680 (GK104, Kepler)** 




http://www.nvidia.com/content/PDF/productspecifications/GeForce GTX 680 Whitepaper FINAL.pdf


#### **Streaming Multiprocessor (SM)**

192 cores, 32 special function units, 32 LD/ST units, 4 warp schedulers

- Блоки назначенные на SM логически разбиваются на **группы (warps)** по 32 потока
- Потоки всегда одинаково распределяются по warp-aм (детерминировано, на базе номера потока)
- Если размер блока не кратен размеру группы,
   то последняя группа (warp) потоков блокируется




**NVIDIA GeForce 680 (GK104, Kepler)** 




#### **Streaming Multiprocessor (SM)**

192 cores, 32 special function units, 32 LD/ST units, 4 warp schedulers

- Планировщик (warp scheduler) запускает
  на выполнение группу потоков, у которых «готовы»
  входные данные
- Все активные потоки группы в каждый момент времени выполняют одну и ту же инструкцию
- Планировщик выполняет переключение контекста между группами потоков



**NVIDIA GeForce 680 (GK104, Kepler)** 



http://www.nvidia.com/content/PDF/product-specifications/GeForce GTX 680 Whitepaper FINAL.pdf

#### **Streaming Multiprocessor (SM)**

192 cores, 32 special function units, 32 LD/ST units, 4 warp schedulers

### **Control Flow Divergence**


- Все потоки группы в каждый момент времени выполняют одну и ту же инструкцию
- Что если потоки управления расходятся?

```
__global__ void kernel()
{
    if (val < 50) {
        // branch 1
    } else {
        // branch 2
    }
}</pre>
```

#### Потоки группы выполняют обе ветви

Потоки, которые не должны выполнять ветвь, блокируются

**NVIDIA GeForce 680 (GK104, Kepler)** 



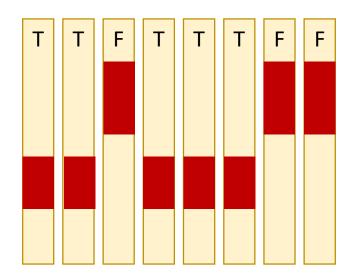
http://www.nvidia.com/content/PDF/productspecifications/GeForce GTX 680 Whitepaper FINAL.pdf

#### **Streaming Multiprocessor (SM)**


192 cores, 32 special function units, 32 LD/ST units, 4 warp schedulers

## **Control Flow Divergence**

```
__global__ void kernel()
{
    if (val < 50) {
        // branch 1
        // branch 1
        // branch 1
    } else {
        // branch 2
        // branch 2
        // branch 2
}</pre>
```



**NVIDIA GeForce 680 (GK104, Kepler)** 




# **NVIDIA GeForce 680 (GK104, Kepler microarch.)**


### **4 Graphics Processing Clusters (GPC)**

2 Streaming Multiprocessor (SMX)

#### **Streaming Multiprocessor (SMX)**

192 cores, 32 special function units, 32 LD/ST units, 4 warp schedulers

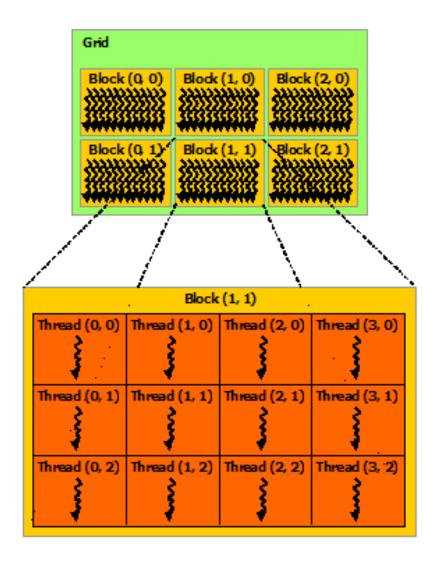




## Информация об устройстве (cngpu1)

```
./deviceQuery Starting...
 CUDA Device Query (Runtime API) version (CUDART static linking)
Detected 1 CUDA Capable device(s)
Device 0: "GeForce GTX 680"
  CUDA Driver Version / Runtime Version 7.5 / 7.5
  CUDA Capability Major/Minor version number:
  Total amount of global memory:
                                                2048 MBytes (2147287040 bytes)
  (8) Multiprocessors, (192) CUDA Cores/MP:
                                               1536 CUDA Cores
  GPU Max Clock rate:
                                                1058 MHz (1.06 GHz)
  Memory Clock rate:
                                                3004 Mhz
  Memory Bus Width:
                                                256-bit
  L2 Cache Size:
                                                524288 bytes
                                                32
  Warp size:
  Maximum number of threads per multiprocessor: 2048
  Maximum number of threads per block:
                                               1024
  Max dimension size of a thread block (x,y,z): (1024, 1024, 64)
  Max dimension size of a grid size (x,y,z): (2147483647, 65535, 65535)
```

## Иерархия потоков



- Сетка потоков (1D, 2D, 3D) совокупность блоков потоков
- Сетка потоков, CUDA-программа, выполняется GPU

- Блок потоков (1D, 2D, 3D) совокупность потоков
- Блоки распределяются по потоковым мультипроцессорам

```
Device 0: "GeForce GTX 680"

Max dimension size of a thread block (x,y,z): (1024, 1024, 64)

Max dimension size of a grid size (x,y,z): (2147483647, 65535, 65535)

...
```

## Иерархия потоков


## Предопределенные переменные

- threadIdx.{x, y, z} –номер потока в блоке
- blockDim.{x, y, z} –размерность блока
- blockIdx.{x, y, z} –
   номер блока в сетке

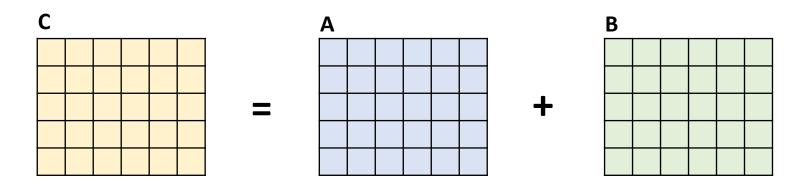
## • Здание структуры сетки

mykernel<<<B,T>>>(arg1, ...);

- В структура сетки
- Т структура блока




## Сложение матриц: CPU



```
void matadd_host(float *a, float *b, float *c, int m, int n)
{
    for (int i = 0; i < m; i++) {
        for (int j = 0; j < n; j++) {
            int idx = i * n + j;
            c[idx] = a[idx] + b[idx];
        }
    }
}</pre>
```

## Сложение матриц: CUDA 1D

- Каждый поток вычисляет один элемент c[i \* n + j] матрицы
- Одномерные сетка блоков потоков и одномерные блоки потоков



Thread global ID | 10 | 11 | 12 | 13 | 14 | <mark>15</mark> | 16 | 17 | 18 | 19 | 20 | 21 | 22 | 23 5 6 8 9 1D-сетка из threadIdx.x 5 6 5 0 3-х 1D-блоков потоков blockIdx.x = 0blockldx.x = 1blockIdx.x = 2

```
__global__ void matadd(const float *a, const float *b, float *c, int m, int n)
{
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < m * n)
        c[idx] = a[idx] + b[idx];
}


{
    int threadsPerBlock = 1024;
    int blocksPerGrid = (ROWS * COLS + threadsPerBlock - 1) / threadsPerBlock;
    matadd<<<<bloom>blocksPerGrid = (ROWS * COLS + threadsPerBlock - 1) / threadsPerBlock;
    matadd<<<<bloom>blocksPerGrid = (ROWS * COLS + threadsPerBlock - 1) / threadsPerBlock;
    matadd<<<<br/>blocksPerGrid = (ROWS * COLS + threadsPerBlock - 1) / threadsPerBlock;
```

## Сложение матриц: CUDA 2D

- Каждый поток вычисляет один элемент c[i \* n + j] матрицы
- 2D-сетка блоков потоков и 2D-блоки потоков

threadIdx.x threadIdx.y	blockldx.x = 3			blockldx.x = 2			blockIdx.x = 1			blockIdx.x = 0		
	(2,0)	(1,0)	(0,0)	(2,0)	(1,0)	(0,0)	(2,0)	(1,0)	(0,0)	(2,0)	(1,0)	(0,0)
lockIdx.y = 0	(2,1) b	(1,1)	(0,1)	(2,1)	(1,1)	(0,1)	(2,1)	(1,1)	(0,1)	(2,1)	(1,1)	(0,1)
	(2,2)	(1,2)	(0,2)	(2,2)	(1,2)	(0,2)	(2,2)	(1,2)	(0,2)	(2,2)	(1,2)	(0,2)
	(2,0)	(1,0)	(0,0)	(2,0)	(1,0)	(0,0)	(2,0)	(1,0)	(0,0)	(2,0)	(1,0)	(0,0)
blockldx.y = 1	(2,1) k	(1,1)	(0,1)	(2,1)	(1,1)	(0,1)	(2,1)	(1,1)	(0,1)	(2,1)	(1,1)	(0,1)
	(2,2)	(1,2)	(0,2)	(2,2)	(1,2)	(0,2)	(2,2)	(1,2)	(0,2)	(2,2)	(1,2)	(0,2)

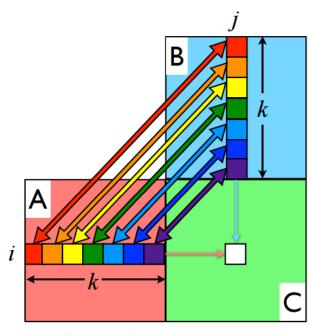
## Умножение матриц (CPU)



## Умножение матриц (CUDA)

- Каждый поток вычисляет один элемент результирующей матрицы С
- Общее число потоков N \* N

```
_global__ void sgemm(const float *a, const float *b, float *c, int n)
  int row = blockIdx.y * blockDim.y + threadIdx.y;
  int col = blockIdx.x * blockDim.x + threadIdx.x;
  if (row < n && col < n) {</pre>
      float s = 0.0;
      for (int k = 0; k < n; k++)
          s += a[row * n + k] * b[k * n + col];
      c[row * n + col] = s;
  int threadsPerBlockDim = 32;
  dim3 blockDim(threadsPerBlockDim, threadsPerBlockDim, 1);
  int blocksPerGridDimX = ceilf(N / (float)threadsPerBlockDim);
  int blocksPerGridDimY = ceilf(N / (float)threadsPerBlockDim);
  dim3 gridDim(blocksPerGridDimX, blocksPerGridDimY, 1);
  sgemm<<<gridDim, blockDim>>>(d A, d B, d C, N);
```



http://users.wfu.edu/choss/CUDA/docs/Lecture%205.pdf