# Семинар 18 Технология СUDA Параллельная редукция

#### Михаил Курносов

E-mail: mkurnosov@gmail.com WWW: www.mkurnosov.net

Цикл семинаров «Основы параллельного программирования» Институт физики полупроводников им. А. В. Ржанова СО РАН Новосибирск, 2015



# Редукция (reduction)

- Задан массив v[0..n-1] из n элементов и ассоциативная операция  $\otimes$
- Необходимо вычислить результаты редукции

$$r = v[0] \otimes v[1] \otimes ... \otimes v[n-1]$$

• Пример:

$$v[0..5] = [5, 8, 3, 12, 1, 7]$$
  
 $r = ((((5 + 8) + 3) + 12) + 1) + 7 = 36$ 

## Последовательная версия (float)

```
void reduce_cpu(float *v, int n, float *sum)
    float s = 0.0;
    for (int i = 0; i < n; i++)
        s += v[i];
    *sum = s;
int n = 10000;
for (size_t i = 0; i < n; i++)
   v[i] = i + 1.0;
```


reduce cpu(v, n, &sum);

- Floating-point Summation // <a href="http://www.drdobbs.com/floating-point-summation/184403224">http://www.drdobbs.com/floating-point-summation/184403224</a>
- David Goldberg. What Every Computer Scientist Should Know About Floating-Point Arithmetic // ACM Computing Surveys, Vol. 23, #1, March 1991, pp. 5-48.

```
# Real sum = 50005000
Sum (CPU) = 50002896.000000, err = 2104.000000
```


# Последовательная версия (int)

```
void reduce_cpu(int *v, int n, int *sum)
{
    int s = 0.0;
    for (int i = 0; i < n; i++)
        s += v[i];
    *sum = s;
}</pre>
```



- Каждый блок потоков обрабатывает часть массива v[0..n 1]
- Поток 0 каждого блока сохраняет результат редукции в массив per\_block\_sum[0..blocks 1]
- Для выполнения редукции массива per\_block\_sum[] нужен еще один шаг на GPU или CPU:

```
cudaMemcpy(sums, per_block_sum, sizeof(int) * blocks, cudaMemcpyDeviceToHost);
int sum_gpu = 0;
for (int i = 0; i < blocks; i++)
    sum_gpu += sums[i];</pre>
```



```
for (int s = 1; s < blockDim.x; s *= 2) {
   if (tid % (2 * s) == 0)
      sdata[tid] += sdata[tid + s];
}</pre>
```


- Каждый поток по своему номеру tid определяет с кем ему взаимодействовать
- На шаге 1 каждый 2-й поток взаимодействует с соседом справа на расстоянии s = 1
- На шаге 2 каждый 4-й поток взаимодействует с соседом справа на расстоянии s = 2
- На шаге 3 каждый 8-й поток взаимодействует с соседом справа на расстоянии s = 4
- **...**
- Всего шагов O(logn)

```
const int block size = 1024;
const int n = 4 * (1 << 20);
int main()
    size t size = sizeof(int) * n;
    int *v = (int *)malloc(size);
    for (size t i = 0; i < n; i++)
       v[i] = i + 1;
   int sum;
   reduce cpu(v, n, &sum);
    /* Allocate on device */
    int threads per block = block size;
    int blocks = (n + threads per block - 1) / threads per block;
    int *dv, *per block sum;
    int *sums = (int *)malloc(sizeof(int) * blocks);
    tmem = -wtime();
    cudaMalloc((void **)&per_block_sum, sizeof(int) * blocks);
    cudaMalloc((void **)&dv, size);
    cudaMemcpy(dv, v, size, cudaMemcpyHostToDevice);
    tmem += wtime();
```


```
/* Compute per block sum: stage 1 */
tgpu = -wtime();
reduce_per_block<<<blocks, threads_per_block>>>(dv, n, per_block_sum);
cudaDeviceSynchronize();
tgpu += wtime();
tmem = -wtime();
cudaMemcpy(sums, per block sum, sizeof(int) * blocks, cudaMemcpyDeviceToHost);
tmem += wtime();
/* Compute block sum: stage 2 */
tgpu -= wtime();
int sum gpu = 0;
for (int i = 0; i < blocks; i++)</pre>
    sum gpu += sums[i];
tgpu += wtime();
printf("CPU version (sec.): %.6f\n", tcpu);
printf("GPU version (sec.): %.6f\n", tgpu);
printf("GPU bandwidth (GiB/s): %.2f\n", 1.0e-9 * size / (tgpu + tmem));
printf("Speedup: %.2f\n", tcpu / tgpu);
printf("Speedup (with mem ops.): %.2f\n", tcpu / (tgpu + tmem));
```

```
_global__ void reduce_per_block(int *v, int n, int *per_block_sum)
   shared int sdata[block size];
   int tid = threadIdx.x;
                                                                        Values (shared memory)
   int i = blockIdx.x * blockDim.x + threadIdx.x;
                                                                           Stride 1
   if (i < n) {
                                                                                 Thread
                                                                           Step 2
                                                                           Stride 2
         sdata[tid] = v[i];
                                                                                                    | 5 | 4 | -3 | 9 | 7 | 13 | 11 | 2 | 2
                                                                                              6 | -2 | 8 |
                                                                           Step 3
                                                                                 Thread
         syncthreads();
                                                                           Stride 4
                                                                                          7 | -1 | 6 | -2 | 8 | 5 | 17 | -3 | 9 | 7 | 13 | 11 | 2 | 2
                                                                                 Thread
         for (int s = 1; s < blockDim.x; s *= 2) {</pre>
                                                                           Stride 8
              if (tid \% (2 * s) == 0)
                   sdata[tid] += sdata[tid + s];
              syncthreads();
                                                                        CUDA kernel launch with 4096 blocks of 1024 threads
                                                                       Sum (CPU) = 2097152
         if (tid == 0)
                                                                       Sum (GPU) = 2097152
              per_block_sum[blockIdx.x] = sdata[0];
                                                                       CPU version (sec.): 0.005956
                                                                       GPU version (sec.): 0.002198
                                                                       GPU bandwidth (GiB/s): 7.56
                                                                       Speedup: 2.71
                                                                        Speedup (with mem ops.): 2.68
```

```
_global___ void reduce_per_block(int *v, int n, int *per_block_sum)
  shared int sdata[block size];
  int tid = threadIdx.x;
  int i = blockIdx.x * blockDim.x + threadIdx.x;
  if (i < n) {
      sdata[tid] = v[i];
      __syncthreads();
      for (int s = 1; s < blockDim.x; s *= 2) {</pre>
          if (tid \% (2 * s) == 0)
              sdata[tid] += sdata[tid + s];
          syncthreads();
      if (tid == 0)
          per_block_sum[blockIdx.x] = sdata[0];
```



Результат условия зависит от номера потока — часть потоков деактивируется (control flow divergence)




#### Control flow divergence!

```
for (int s = 1; s < blockDim.x; s *= 2) {
    if (tid % (2 * s) == 0)
        sdata[tid] += sdata[tid + s];
    __syncthreads();
}</pre>
```

```
for (int s = 1; s < blockDim.x; s *= 2) {
   int index = 2 * s * tid;
   if (index < blockDim.x)
       sdata[index] += sdata[index + s];
       __syncthreads();
}</pre>
```

```
global void reduce per block(int *v, int n, int *per block sum)
   shared int sdata[block size];
   int tid = threadIdx.x;
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   if (i < n) {</pre>
       sdata[tid] = v[i];
       __syncthreads();
       for (int s = 1; s < blockDim.x; s *= 2) {</pre>
           int index = 2 * s * tid;
           if (index < blockDim.x)</pre>
               sdata[index] += sdata[index + s];
           syncthreads();
       if (tid == 0)
           per block sum[blockIdx.x] = sdata[0];
```



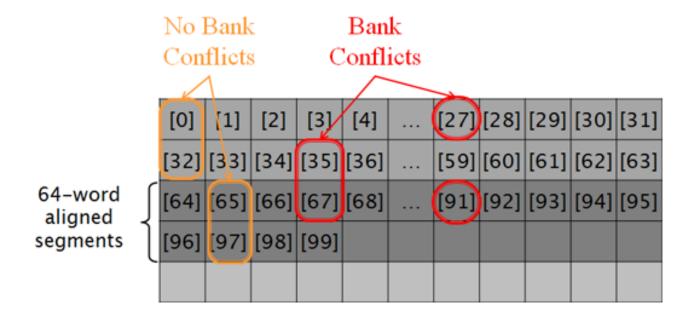
```
CUDA kernel launch with 4096 blocks of 1024 threads Sum (CPU) = 2097152
Sum (GPU) = 2097152
CPU version (sec.): 0.006481
GPU version (sec.): 0.001968
GPU bandwidth (GiB/s): 8.44
Speedup: 3.29
Speedup (with mem ops.): 3.26
```

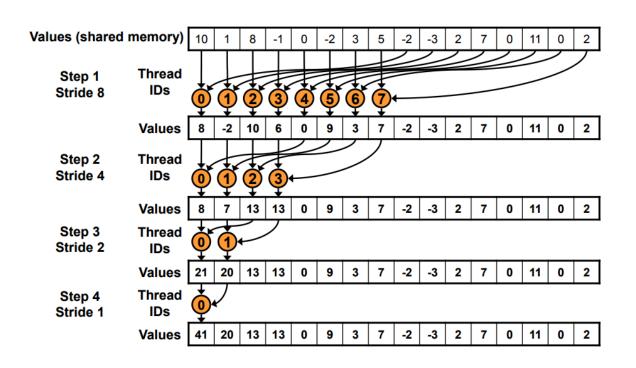
```
global void reduce per block(int *v, int n, int *per block sum)
   shared int sdata[block size];
   int tid = threadIdx.x;
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   if (i < n) {</pre>
       sdata[tid] = v[i];
       __syncthreads();
       for (int s = 1; s < blockDim.x; s *= 2) {</pre>
           int index = 2 * s * tid;
           if (index < blockDim.x)</pre>
               sdata[index] += sdata[index + s];
           syncthreads();
       if (tid == 0)
           per_block_sum[blockIdx.x] = sdata[0];
```

- Обращение к разделяемой памяти выполняется через 32 параллельно функционирующих банка
- Каждый банк 4 байта (настраивается)
- Номер банка = адрес % 32
- Одновременный доступ к одному банку сериализуется!

TID	S = 1	S = 2	S = 4
0	0-1 // banks 0, 1	0-2 <b>// banks 0, 1</b>	0-4 // banks 0, 1
1	2-3 // banks 2, 3	4-6 <b>// banks 2, 3</b>	
2	4-5 // banks 4, 5	8-10 <b>// banks 4, 5</b>	
3	6-7 // banks 6, 7	12-14 <b>// banks 6, 7</b>	24-28 // banks 24, 28
4	8-9 // banks 8, 9	16-18 // banks 8, 9	32-36 <b>// banks 0, 2</b>
8		32-34 <b>// banks 0, 2</b>	
9		36-38 <b>// banks 4, 6</b>	

# **Shared memory bank conflicts**






#### **Bank conflicts**

```
for (int s = 1; s < blockDim.x; s *= 2) {
   int index = 2 * s * tid;
   if (index < blockDim.x)
        sdata[index] += sdata[index + s];
        __syncthreads();
}</pre>
for (int s = blockDim.x / 2; s > 0; s >>= 1) {
      if (tid < s)
        sdata[tid] += sdata[tid + s];
        __syncthreads();
}</pre>
__syncthreads();
```

```
__global__ void reduce_per_block(int *v, int n, int *per_block_sum)
   shared int sdata[block size];
   int tid = threadIdx.x;
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   if (i < n) {
       sdata[tid] = v[i];
       syncthreads();
       for (int s = blockDim.x / 2; s > 0; s >>= 1) {
           if (tid < s)
               sdata[tid] += sdata[tid + s];
           syncthreads();
       if (tid == 0)
           per block sum[blockIdx.x] = sdata[0];
```



```
CUDA kernel launch with 4096 blocks of 1024 threads Sum (CPU) = 2097152
Sum (GPU) = 2097152
CPU version (sec.): 0.004661
GPU version (sec.): 0.001163
GPU bandwidth (GiB/s): 14.17
Speedup: 4.01
Speedup (with mem ops.): 3.94
```

## Задание

■ Реализовать второй шаг редукции на GPU — редукция по массиву per\_block\_sum[] <a href="https://code.google.com/p/stanford-cs193g-sp2010/source/browse/trunk/tutorials/sum\_reduction.cu">https://code.google.com/p/stanford-cs193g-sp2010/source/browse/trunk/tutorials/sum\_reduction.cu</a>

■ Реализовать первое сложение при загрузке данных в разделяемую память и разворачивание цикла (loop unrolling):
 https://docs.nvidia.com/cuda/samples/6 Advanced/reduction/doc/reduction.pdf

- SDK Samples/6\_Advanced/reduction
- Faster Parallel Reductions on Kepler // http://devblogs.nvidia.com/parallelforall/faster-parallel-reductions-kepler/